本报告可独立阅读与打印。证据路径仅供持有项目副本的读者本地追溯。

管网缺陷检测模型与复检策略完整测试报告

项目：sewer-agent ｜ 用途：公司技术评估与结果审阅 ｜ 报告日期：2026-11-09

实验时间：2026-09-17 至 2026-09-23。报告汇总历史模型推理、策略重放及图像级重新评分；2026-11-09 补齐缓存分类统计，不包含新的训练或模型调用。

1 执行摘要

本次评估针对 CCTV 图片中的五类管道缺陷，回答三个问题：联合训练是否改善跨来源表现，VLM 复检及融合是否优于单独模型，以及按“定位缺陷”和“判断图片中有哪些类别”两种业务目标评分时有何差别。

主要结论如下。

1. 新 YOLO26m 改善了 SEDD 同来源留出集适配。 固定阈值下，SEDD 召回率由旧模型的 5.80% 提高至 71.01%，F1 从 10.13% 提高至 67.59%；这不是对全新未见数据源的泛化保证。
2. 606 图框级对照中，旧自动融合未超过纯 YOLO。 同次运行的 YOLO F1 为 67.16%，纯 VLM 为 25.21%，旧融合为 56.82%。后续保守融合保留 YOLO 原框，缓存重放 F1 恢复为 67.16%，但未形成超过基线的自动检测增益。
3. 类别识别与定位能力应分别报告。 606 图的 YOLO 图像级 F1 为 89.46%，整图类别完全正确率为 82.67%；60 图校准子集的对应指标为 90.77% 和 80.00%。图像级高分不表示框位置、数量也正确。
4. VLM 的补充建议具有可供人工核查的价值，但自动纳入仍有代价。 60 图首轮新增框将图像级召回从 84.29% 提高到 87.14%，同时将精确率从 98.33% 降至 80.26%；二次确认减少了一部分不匹配预测，仍未整体超越基线。

现有结果支持保留“纯 YOLO”和“YOLO＋VLM 保守复检”两条使用路径，并保留 VLM 分歧和新增线索供审核；不支持宣称融合已普遍优于单模型，也不支持将任一图像级分数称为无条件的“检测准确率”。

2 数据集与类别范围

2.1 数据清理与固定划分

合并数据版本为 `merged_five_v1`。原始 sewer2403 共 19,049 张，纳入 11,244 张；原始 SEDD 共 7,563 张，纳入 876 张。排除五类以外及目标类与其他类混合标注的整张图片，同时处理预增强副本、无效框、重复和标注冲突。

来源	训练集	验证集	测试集	合计
sewer2403	10,119	563	562	11,244
SEDD	789	43	44	876
合计	10,908	606	606	12,120

比例为 90%／5%／5%，划分种子为 20260916。按可恢复的来源别名和近似图片关系分组后划分，形成 9,519 组，已识别的同组关系不跨集合。部分原始管段和视频身份不可恢复，因此不宣称完全管段独立。

SEDD 的 5,001 张无 XML 图片未直接视为正常；924 个文件名冲突的标注暂未纳入。最终只有 32 张 sewer2403 显式空标注图，训练／验证／测试各为 28／2／2，且空标注不等于人工确认无缺陷。

2.2 五类映射与可评范围

统一类别	中文含义	sewer2403 映射	SEDD 映射及评分
AJ	支管暗接	AJ	未标注，不评分
BX	变形	BX	未标注，不评分
FS	腐蚀	FS	未标注，不评分
PL	破裂及裂缝	PL	crack → PL
BLOCK	堵塞类	CJ 沉积、JG 结垢、ZW 障碍物合并	deposit → BLOCK

SEDD 的 root 未映射为 BLOCK。本报告固定阈值指标和分类指标均使用来源类别掩码：SEDD 只评 PL／BLOCK，其他三类不计 TP、FP、FN 或 TN；这不表示其他类别在该图片中不存在。

2.3 两个评测样本群体

群体	样本来源	图片数	标注框数	阳性图片类别对	可评标签位	显式空标注图片
完整测试集	sewer2403 562＋SEDD 44	606	761	621	2,898	2
校准子集	验证集中的 sewer2403 37＋SEDD 23	60	108	70	231	1

60 图不是 606 图测试集的抽样，而是另一份 606 张验证集中的分组隔离校准子集，两者样本 ID 无交集。它采用类别覆盖导向的选样，SEDD 比例较高，不代表测试集自然分布。验证集和测试集都恰好有 606 张，二者不能混用。

类别	606 标注框	606 阳性图	606 可评图	60 标注框	60 阳性图	60 可评图
AJ	100	94	562	12	12	37
BX	16	16	562	12	12	37
FS	44	38	562	13	12	37
PL	390	278	606	57	22	60
BLOCK	211	195	606	14	12	60

一张图可含多个类别，阳性图列之和不等于图片总数。AJ／BX／FS 的可评图片仅来自 sewer2403。

3 模型配置与策略设计

3.1 YOLO26m 训练配置

项目	配置或实测
初始模型	通用预训练 YOLO26m；不是在旧 sewer 权重上续训
输入与批次	输入尺寸 960；batch 16
设备	NVIDIA RTX 5090，32 GB 显存级别
优化	MuSGD；初始学习率 0.01；momentum 0.9；weight decay 0.0005
训练控制	最大 100 epoch；patience 30；AMP 开启；seed 20260916
实际完成	84 epoch；第 54 epoch 最佳；累计约 4.07 小时
检查点	best、last，以及每 10 epoch 周期保存

项目	配置或实测
数据增强	mosaic 1.0、平移 0.1、缩放 0.5、水平翻转 0.5；无 mixup／cutmix

后段训练损失继续下降而验证损失上升，存在过拟合迹象，因此采用 best 而非 last。配置的 close_mosaic=10 原计划在第 90 轮后生效，实际第 84 轮早停，没有进入该阶段。

3.2 各实验策略与覆盖范围

方案	核心行为	606 图	60 图
旧 YOLO26s	原 sewer2403 五类权重，仅诊断参照	9月17日实测	未单独实测
新 YOLO26m	合并数据训练；原始检测框，conf≥0.25	两次运行分别保留	验证导出缓存过滤至 conf≥0.25
纯 VLM	无 YOLO 候选提示，独立识别并输出框	实测606图	未单独实测
旧自动融合	低置信度候选可删改，新增异常可加入最终框	历史实测及重放	未作同协议对照
保守融合	保留全部 YOLO 原框，分歧及新增异常待审	历史 VLM 意见缓存重放	v4 复检实测，原框保留
首轮新增框实验	保守原框＋通过实验门的 VLM 新增框	未作 v4 同协议全量实验	离线投影
二次确认新增框	对首轮提议再请求同一 VLM，合格候选才加入	未作同协议全量实验	23 个提议的二次请求

空缺项代表没有对应实验，不能用另一个群体的成绩填补。旧 YOLO26s 可能见过新划分中的 sewer2403 测试图或近邻，其高分不作为公平独立模型排名。

3.3 VLM 输入与融合规则

VLM 使用 Qwen API 模型 `qwen3.8-max`。保存的请求配置为关闭 thinking、最大输出 4,096 token、超时 60 秒；对照实验不调用额外的文本任务解析 LLM。

纯 VLM 使用 `image-discovery-v2`，输入原图，较大图片可附带独立分块视图，没有 YOLO 预测提示。606 图引导复检使用 `yolo-guided-review-v2`，输入原图、YOLO 候选类别／分数／坐标和候选区域局部图；检测框通过结构化元数据提供，不把图库中画框后的展示图当成唯一视觉输入。

60 图使用 `yolo-guided-review-v4`，将“原类别是否存在”与“同区域是否存在其他类别”分开回答，并对新增异常记录确认状态。候选局部图来自原图区域，不是增强后的合成证据。两批 Prompt 和样本分布不同，不能用跨批分数差异直接衡量 v4 的净收益。

旧融合 `guided-confidence-v2` 采用全局 0.85 保护阈值；低于阈值的框可能被拒绝或改类。新框中的 score=1.0 是历史融合的排序占位值，不是真实置信概率。保守融合 `guided-conservative-v1` 不自动删改 YOLO 框；新增线索默认待人工审核，因此评测原框可以与 YOLO 完全一致。

60 图 C 方案只加入首轮实际通过实验门的新增框，不是所有文字建议。D 方案对其中 23 个提议分别发起新请求，依据图像可判读、accept、original_presence=present 和 clear 等条件接受 14 个；2 个请求失败，不升级为新增框。同一模型的第二次请求并不构成独立模型或人工证据。

4 评测目标与指标定义

4.1 目标检测评测

目标是判断缺陷的类别、位置和实例数量。将预测按分数降序排列，在同一图片、同一类别内按 IoU≥0.5 与尚未匹配的标注一对一匹配。命中为 TP，未匹配预测为 FP，未匹配标注为 FN；重复框可能计为 FP。框级 TP／FP／FN 的单位是缺陷实例，不定义数量无限的背景真负框 TN。

IoU＝预测框与标注框交集面积／并集面积。固定工作点评测使用 YOLO conf≥0.25。mAP50 是 IoU=0.5 下各类别 AP 的平均，mAP50–95 进一步平均 IoU 0.50 至 0.95、间隔 0.05 的 AP；AP 综合置信度曲线，不能与固定阈值 F1 互换。

本次原生 mAP 用 conf 下限 0.001、输入 960、batch 16、FP32。原生输出的 P／R 是曲线工作点统计，不作为表中 conf=0.25 的 P／R。纯 VLM 和融合输出未保存可比的完整校准置信曲线，本报告不为其补造 mAP、AUROC 或 AUPRC。

4.2 图像级多标签分类评测

目标是判断“这张图出现了哪些目标类别”。对已有标注框和预测框分别提取类别集合，再与该来源可评类别取交集；同类多个框只算一次，不检查框位置、大小或实例数。这不是重新训练分类器，也不是从自由文本中额外提取类别。

设每张图的标注类别集合为 G、预测集合为 P：TP=|G∩P|，FP=|P−G|，FN=|G−P|；其余可评类别位为 TN。图像级计数单位是“图片—类别”，不与框级数量直接相减。

指标	定义	主要用途与解释
Precision 精确率	TP／(TP＋FP)	已报结果中与标注相符的比例；不是正常图无误报率
Recall 召回率	TP／(TP＋FN)	标注目标中被找回的比例
F1	2TP／(2TP＋FP＋FN)	平衡精确率和召回率
Micro P／R／F1	先汇总所有可评 TP／FP／FN，再计算	常见类别贡献较大；默认表格采用此口径
Macro P／R／F1	每个可评类别分别计算，再等权平均	观察稀有类别；Macro F1 不是 Macro P／R 的调和平均
整图完全正确率	预测类别集合与标注完全相同的图片数／总图数	多报或少报任一类别，该图均不完全正确
Hamming loss	(FP＋FN)／可评标签位总数	越低越好；606 图分母 2,898，60 图分母 231
标签位准确率	(TP＋TN)／可评标签位总数	等于 1−Hamming loss；易受大量未出现类别影响

分母为零的 P／R／F1 记为 0，与既有评分器一致。来源内 Macro 仅平均该来源的可评类别，混合统计平均五类。报告百分比保留两位小数，原始 CSV／JSON 保存完整精度。

4.3 为什么两种分数不能互相替代

一张图即使有多处 PL 裂缝，只报出一处 PL，分类仍可能完全正确；检测评测则会记录其他裂缝漏检。反之，在没有标注 FS 的图片上额外报告 FS，分类仍会计 FP，不能通过改成分类口径消除整类漏标影响。二分类“有异常／无异常”会进一步丢失类别信息，且本数据正常图极少，本报告不将其作为效果验收主指标。

5 新模型训练后基线结果

5.1 原生 mAP

数据范围	mAP50	mAP50–95
验证606图	65.38%	44.10%
混合测试606图（参考）	63.20%	42.20%
sewer2403测试562图	63.18%	42.47%
SEDD测试44图	76.11%	42.35%

原生混合 mAP 没有逐来源屏蔽 SEDD 未标注的三类，主要依据应为来源拆分结果。固定阈值和分类表均执行来源掩码，不与原生混合 mAP 直接等同。

5.2 新旧模型固定阈值对照

以下为 9月17日的同次评估，旧模型只作诊断参照。

来源	模型	TP / FP / FN	P	R	F1
mixed	旧 YOLO26s	610 / 130 / 151	82.43%	80.16%	81.28%
mixed	新 YOLO26m	500 / 231 / 261	68.40%	65.70%	67.02%
sewer2403	旧 YOLO26s	606 / 124 / 86	83.01%	87.57%	85.23%
sewer2403	新 YOLO26m	451 / 204 / 241	68.85%	65.17%	66.96%
sedd	旧 YOLO26s	4 / 6 / 65	40.00%	5.80%	10.13%
sedd	新 YOLO26m	49 / 27 / 20	64.47%	71.01%	67.59%

5.3 新模型逐类基线

P／R／F1 为 0.25 固定工作点；AP 列为另行原生曲线评测，同表呈现但不混用。

来源	类别	标注框	P	R	F1	AP50	AP50–95
sewer2403	AJ	100	80.00%	84.00%	81.95%	89.69%	70.37%
sewer2403	BX	16	38.89%	43.75%	41.18%	40.99%	22.69%
sewer2403	FS	44	62.96%	38.64%	47.89%	44.58%	26.36%
sewer2403	PL	341	62.34%	57.77%	59.97%	58.58%	31.16%
sewer2403	BLOCK	191	77.25%	76.44%	76.84%	82.07%	61.79%
sedd	PL	49	57.69%	61.22%	59.41%	60.43%	34.94%
sedd	BLOCK	20	79.17%	95.00%	86.36%	91.79%	49.75%

AJ、BLOCK 相对较强，BX、FS 相对较弱。训练阳性图中 BX 只有 288 张、FS 677 张，且 BX 测试仅16图；类别不均衡是明确风险，但不足以单独证明退化原因。

6 完整606图目标检测对照

6.1 总体结果

以下以 9月18日引导复检同次运行的原始 YOLO 为基线。其 TP=501，与 9月17日独立运行的 TP=500 相差一个匹配框；保留各自记录，不挑选较高结果替换历史成绩。

方案	TP / FP / FN	P	R	F1
新 YOLO26m	501 / 230 / 260	68.54%	65.83%	67.16%
纯 VLM	251 / 979 / 510	20.41%	32.98%	25.21%
旧自动融合	477 / 441 / 284	51.96%	62.68%	56.82%
保守融合重放	501 / 230 / 260	68.54%	65.83%	67.16%

相对同次 YOLO 基线，旧融合 TP 减少24、FP 增加211、FN 增加24，F1 下降10.34个百分点。保守重放逐图验证与原 YOLO 框一致，说明它阻止了自动删改造成的损失，而非验证了新增检测收益。

6.2 分来源结果

保守重放与 YOLO 完全相同，下表合并表示；SEDD 仅评 PL／BLOCK。

来源	方案	TP / FP / FN	P	R	F1
sewer2403（562图）	YOLO／保守	452 / 203 / 240	69.01%	65.32%	67.11%
sewer2403（562图）	纯 VLM	243 / 917 / 449	20.95%	35.12%	26.24%
sewer2403（562图）	旧融合	433 / 415 / 259	51.06%	62.57%	56.23%
sedd（44图）	YOLO／保守	49 / 27 / 20	64.47%	71.01%	67.59%
sedd（44图）	纯 VLM	8 / 62 / 61	11.43%	11.59%	11.51%
sedd（44图）	旧融合	44 / 26 / 25	62.86%	63.77%	63.31%

6.3 五类结果

PL／BLOCK 合并两来源，AJ／BX／FS 仅统计 sewer2403。

类别	方案	TP / FP / FN	P	R	F1
AJ	YOLO／保守	84 / 20 / 16	80.77%	84.00%	82.35%
AJ	纯 VLM	43 / 19 / 57	69.35%	43.00%	53.09%
AJ	旧融合	78 / 16 / 22	82.98%	78.00%	80.41%
BX	YOLO／保守	7 / 11 / 9	38.89%	43.75%	41.18%
BX	纯 VLM	0 / 6 / 16	0.00%	0.00%	0.00%
BX	旧融合	3 / 8 / 13	27.27%	18.75%	22.22%
FS	YOLO／保守	17 / 10 / 27	62.96%	38.64%	47.89%
FS	纯 VLM	1 / 319 / 43	0.31%	2.27%	0.55%
FS	旧融合	5 / 73 / 39	6.41%	11.36%	8.20%
PL	YOLO／保守	228 / 141 / 162	61.79%	58.46%	60.08%

类别	方案	TP / FP / FN	P	R	F1
PL	纯 VLM	114 / 362 / 276	23.95%	29.23%	26.33%
PL	旧融合	221 / 229 / 169	49.11%	56.67%	52.62%
BLOCK	YOLO／保守	165 / 48 / 46	77.46%	78.20%	77.83%
BLOCK	纯 VLM	93 / 273 / 118	25.41%	44.08%	32.24%
BLOCK	旧融合	170 / 115 / 41	59.65%	80.57%	68.55%

纯 VLM 在本组 BX 框级 TP 为0，FS 仅1；旧融合也降低了 BX／FS 的召回。额外异常可能受到标注完整性影响，但自动删改原本匹配的候选框也会独立造成损失，不能全部归因于漏标。

7 完整606图图像级多标签结果

本节由同一批历史预测离线补算。没有修改框、类别、阈值或标注，且不额外计入 VLM 文字中没有落入预测框集合的类别。

7.1 总体分类结果

方案	TP / FP / FN	P	R	F1	整图完全正确
新 YOLO26m	526 / 29 / 95	94.77%	84.70%	89.46%	501/606（82.67%）
纯 VLM	522 / 565 / 99	48.02%	84.06%	61.12%	176/606（29.04%）
旧自动融合	532 / 199 / 89	72.78%	85.67%	78.70%	404/606（66.67%）
保守融合重放	526 / 29 / 95	94.77%	84.70%	89.46%	501/606（82.67%）

旧融合比 YOLO 多找回6个图片—类别对，但多出170个不匹配类别预测，图像级 F1 仍下降10.76个百分点。纯 VLM 图像级召回接近 YOLO，但精确率明显偏低；去掉定位考核并未消除额外类别报告的问题。

7.2 宏平均与标签位指标

方案	Macro P	Macro R	Macro F1	TN	Hamming loss ↓	标签位准确率
新 YOLO26m	88.46%	76.49%	81.51%	2248	4.28%	95.72%
纯 VLM	47.69%	66.12%	48.65%	1712	22.91%	77.09%
旧自动融合	62.75%	66.17%	63.26%	2078	9.94%	90.06%
保守融合重放	88.46%	76.49%	81.51%	2248	4.28%	95.72%

YOLO 图像级 Micro F1 89.46% 高于 Macro F1 81.51%，说明整体分数受到常见类别的贡献影响。标签位准确率包含2,248个 TN，不应替代整图完全正确率或正常场景误报率。

7.3 分来源分类结果

来源	方案	TP / FP / FN	P	R	F1	整图完全正确
sewer2403（562图）	YOLO／保守	480 / 25 / 94	95.05%	83.62%	88.97%	462/562（82.21%）
sewer2403（562图）	纯 VLM	483 / 549 / 91	46.80%	84.15%	60.15%	151/562（26.87%）
sewer2403（562图）	旧融合	490 / 195 / 84	71.53%	85.37%	77.84%	369/562（65.66%）
sedd（44图）	YOLO／保守	46 / 4 / 1	92.00%	97.87%	94.85%	39/44（88.64%）

来源	方案	TP / FP / FN	P	R	F1	整图完全正确
sedd（44图）	纯 VLM	39 / 16 / 8	70.91%	82.98%	76.47%	25/44（56.82%）
sedd（44图）	旧融合	42 / 4 / 5	91.30%	89.36%	90.32%	35/44（79.55%）

7.4 五类分类结果

类别	方案	TP / FP / FN	P	R	F1
AJ	YOLO／保守	88 / 2 / 6	97.78%	93.62%	95.65%
AJ	纯 VLM	54 / 6 / 40	90.00%	57.45%	70.13%
AJ	旧融合	84 / 3 / 10	96.55%	89.36%	92.82%
BX	YOLO／保守	10 / 5 / 6	66.67%	62.50%	64.52%
BX	纯 VLM	1 / 5 / 15	16.67%	6.25%	9.09%
BX	旧融合	5 / 5 / 11	50.00%	31.25%	38.46%
FS	YOLO／保守	20 / 3 / 18	86.96%	52.63%	65.57%
FS	纯 VLM	31 / 275 / 7	10.13%	81.58%	18.02%
FS	旧融合	10 / 63 / 28	13.70%	26.32%	18.02%
PL	YOLO／保守	232 / 9 / 46	96.27%	83.45%	89.40%
PL	纯 VLM	250 / 114 / 28	68.68%	89.93%	77.88%
PL	旧融合	249 / 56 / 29	81.64%	89.57%	85.42%
BLOCK	YOLO／保守	176 / 10 / 19	94.62%	90.26%	92.39%
BLOCK	纯 VLM	186 / 165 / 9	52.99%	95.38%	68.13%
BLOCK	旧融合	184 / 72 / 11	71.88%	94.36%	81.60%

8 六十图校准实验结果

本节只使用修正工作点后的 `live-60-conf025` 缓存。首次复检1张失败，保留 YOLO 回退结果；二次确认2个候选失败，不加入新框。所有60张仍参与统计。

8.1 框级结果

方案	TP / FP / FN	P	R	F1
A 纯 YOLO	69 / 38 / 39	64.49%	63.89%	64.19%
B 保守融合	69 / 38 / 39	64.49%	63.89%	64.19%
C 首轮新增框	70 / 60 / 38	53.85%	64.81%	58.82%
D 二次确认新增框	69 / 52 / 39	57.02%	63.89%	60.26%

首轮新增框在标注匹配上净增1个 TP，同时净增22个 FP；二次确认后相对基线没有新增 TP，仍多14个 FP。这里的 FP 是相对参考标注未匹配，不是每个都已人工证实为不存在的缺陷。

8.2 图像级结果

方案	TP / FP / FN	P	R	F1	整图完全正确
A 纯 YOLO	59 / 1 / 11	98.33%	84.29%	90.77%	48/60（80.00%）
B 保守融合	59 / 1 / 11	98.33%	84.29%	90.77%	48/60（80.00%）
C 首轮新增框	61 / 15 / 9	80.26%	87.14%	83.56%	39/60（65.00%）
D 二次确认新增框	59 / 11 / 11	84.29%	84.29%	84.29%	41/60（68.33%）

同一 YOLO／保守预测的 F1 从框级64.19%变为图像级90.77%，变化来自评分单位。C 组图像级召回提高2.86个百分点，精确率下降18.07个百分点；D 组没有在精确率和召回率上同时超过基线。

8.3 分类宏平均与标签位指标

方案	Macro P	Macro R	Macro F1	TN	Hamming loss ↓	标签位准确率
A 纯 YOLO	99.09%	82.42%	89.15%	160	5.19%	94.81%
B 保守融合	99.09%	82.42%	89.15%	160	5.19%	94.81%
C 首轮新增框	84.67%	85.76%	83.98%	146	10.39%	89.61%
D 二次确认新增框	86.76%	82.42%	83.20%	150	9.52%	90.48%

8.4 分来源框级结果

来源	方案	TP / FP / FN	P	R	F1
sewer2403（37图）	A/B YOLO／保守	38 / 20 / 23	65.52%	62.30%	63.87%
sewer2403（37图）	C 首轮新增	39 / 37 / 22	51.32%	63.93%	56.93%
sewer2403（37图）	D 二次确认	38 / 31 / 23	55.07%	62.30%	58.46%
sedd（23图）	A/B YOLO／保守	31 / 18 / 16	63.27%	65.96%	64.58%
sedd（23图）	C 首轮新增	31 / 23 / 16	57.41%	65.96%	61.39%
sedd（23图）	D 二次确认	31 / 21 / 16	59.62%	65.96%	62.63%

8.5 分来源分类结果

来源	方案	TP / FP / FN	P	R	F1	整图完全正确
sewer2403（37图）	A/B YOLO／保守	35 / 0 / 9	100.00%	79.55%	88.61%	28/37（75.68%）
sewer2403（37图）	C 首轮新增	37 / 11 / 7	77.08%	84.09%	80.43%	21/37（56.76%）
sewer2403（37图）	D 二次确认	35 / 9 / 9	79.55%	79.55%	79.55%	22/37（59.46%）
sedd（23图）	A/B YOLO／保守	24 / 1 / 2	96.00%	92.31%	94.12%	20/23（86.96%）
sedd（23图）	C 首轮新增	24 / 4 / 2	85.71%	92.31%	88.89%	18/23（78.26%）
sedd（23图）	D 二次确认	24 / 2 / 2	92.31%	92.31%	92.31%	19/23（82.61%）

8.6 五类框级结果

类别	方案	TP / FP / FN	P	R	F1
AJ	A/B YOLO／保守	10 / 2 / 2	83.33%	83.33%	83.33%
AJ	C 首轮新增	10 / 3 / 2	76.92%	83.33%	80.00%
AJ	D 二次确认	10 / 3 / 2	76.92%	83.33%	80.00%
BX	A/B YOLO／保守	8 / 1 / 4	88.89%	66.67%	76.19%
BX	C 首轮新增	8 / 1 / 4	88.89%	66.67%	76.19%
BX	D 二次确认	8 / 1 / 4	88.89%	66.67%	76.19%
FS	A/B YOLO／保守	5 / 5 / 8	50.00%	38.46%	43.48%
FS	C 首轮新增	6 / 7 / 7	46.15%	46.15%	46.15%
FS	D 二次确认	5 / 6 / 8	45.45%	38.46%	41.67%
PL	A/B YOLO／保守	37 / 27 / 20	57.81%	64.91%	61.16%
PL	C 首轮新增	37 / 37 / 20	50.00%	64.91%	56.49%
PL	D 二次确认	37 / 32 / 20	53.62%	64.91%	58.73%
BLOCK	A/B YOLO／保守	9 / 3 / 5	75.00%	64.29%	69.23%
BLOCK	C 首轮新增	9 / 12 / 5	42.86%	64.29%	51.43%
BLOCK	D 二次确认	9 / 10 / 5	47.37%	64.29%	54.55%

8.7 五类分类结果

类别	方案	TP / FP / FN	P	R	F1
AJ	A/B YOLO／保守	12 / 0 / 0	100.00%	100.00%	100.00%
AJ	C 首轮新增	12 / 0 / 0	100.00%	100.00%	100.00%
AJ	D 二次确认	12 / 0 / 0	100.00%	100.00%	100.00%
BX	A/B YOLO／保守	9 / 0 / 3	100.00%	75.00%	85.71%
BX	C 首轮新增	9 / 0 / 3	100.00%	75.00%	85.71%
BX	D 二次确认	9 / 0 / 3	100.00%	75.00%	85.71%
FS	A/B YOLO／保守	7 / 0 / 5	100.00%	58.33%	73.68%
FS	C 首轮新增	9 / 1 / 3	90.00%	75.00%	81.82%
FS	D 二次确认	7 / 1 / 5	87.50%	58.33%	70.00%
PL	A/B YOLO／保守	21 / 1 / 1	95.45%	95.45%	95.45%
PL	C 首轮新增	21 / 6 / 1	77.78%	95.45%	85.71%
PL	D 二次确认	21 / 3 / 1	87.50%	95.45%	91.30%
BLOCK	A/B YOLO／保守	10 / 0 / 2	100.00%	83.33%	90.91%
BLOCK	C 首轮新增	10 / 8 / 2	55.56%	83.33%	66.67%
BLOCK	D 二次确认	10 / 7 / 2	58.82%	83.33%	68.97%

FS 在 C 组图像级 F1 由73.68%提高到81.82%，是本批可观察到的局部收益，但仍伴随精确率下降；D 组没有保住这项收益。BX 未获得新增召回。PL／BLOCK 的新增不匹配预测是总体精确率下降的重要来源。

9 类别阈值校准及其适用边界

阈值分析使用完整606张验证集的低阈值 YOLO 导出，不使用测试集选阈值。逐类扫描0.00至0.99、步长0.01，在 Precision≥0.75 的候选中优先选择召回最高者；没有合格候选才回退到最大F1。本轮五类均找到达到条件的候选。

类别	候选保护阈值	验证 TP / FP / FN	验证 P	验证 R	验证 F1
AJ	0.02	96 / 26 / 6	78.69%	94.12%	85.71%
BX	0.72	6 / 2 / 10	75.00%	37.50%	50.00%
FS	0.77	9 / 3 / 32	75.00%	21.95%	33.96%
PL	0.43	210 / 67 / 179	75.81%	53.98%	63.06%
BLOCK	0.17	173 / 56 / 40	75.55%	81.22%	78.28%

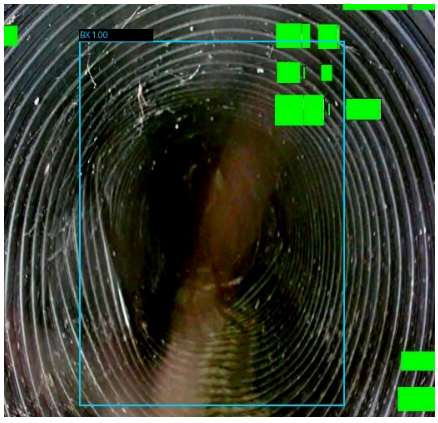
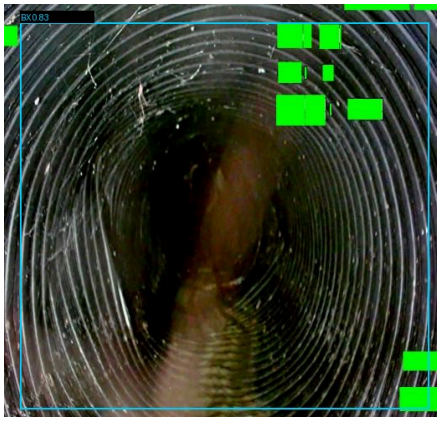
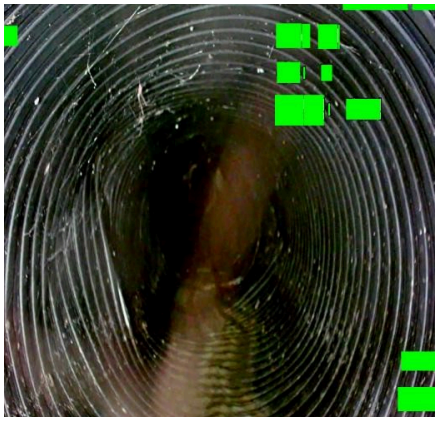
这些值用于分析检测先验的保护偏好，不是本报告606／60图的输出过滤阈值；后者仍为0.25。特别是 AJ=0.02 不表示此次输出包含0.02分框。保守策略即使遇到低于保护阈值的原框，也不自动删除，只保留分歧待审。

验证集上满足逐类75%精确率，不等于测试集或部署结果必定达到75%；BX、FS 的阈值选择分别只保留37.50%、21.95%的验证召回，展示了精确率目标与漏检之间的取舍。60图人工校准模板尚无完成的独立审核结论，VLM 的 confirmed 字段不能替代人工金标准。

10 典型样例与失败环节

10.1 BX 原检测被旧融合撤销

样本 `sewer2403__DF_53_png.rf.5e30f50de9eb202e294d8ffbd9e092e9`。一个 BX 标注，YOLO 分数0.83112且匹配标注；VLM 解释为规则波纹和透视后拒绝。旧融合将 TP/FP/FN 从1/0/0变成0/0/1。保守重放保留原框和分歧意见。

参考标注	YOLO 初检	历史融合结果
		

以上为已有实验图库的同区域裁图，不是本轮重新检测。

10.2 新增 BLOCK 不改变分类得分但影响框级精确率

样本 `sewer2403__911ca174a34a5d7f1cd40e317c7519de`。YOLO 的 BLOCK 分数0.374、与标注 IoU约0.551；旧融合另加一个与唯一标注 IoU为0的 BLOCK 框。类别集合均为 {BLOCK}，分类得分不变；框级由1TP/0FP变为1TP/1FP。额外物体是否属于真实漏标需人工核实。

参考标注	YOLO 初检	历史融合结果
		

10.3 FS 与 PL 共存不能简单改类

样本 `sewer2403__1560_1_jpg.rf.c2a2ff6bc49a50a8c19aaaefe4c975eb` 的标注为1个PL、2个FS。YOLO 原有3个TP；旧融合将一个0.46717分的FS改为PL后，变为2TP/1FP/1FN。对局部裂纹的判断可能与腐蚀共存，识别出另一类并不能证明原类别不存在。

10.4 整图类别正确不保证局部判断正确

60图中的 `sample-0018` 对应 `sedd__01213`。标注、YOLO和保守融合的类别集合都是 {PL, BLOCK}，因此图像级完全正确；但候选#5仍为PL、分数约0.26014，VLM提出同区域BLOCK意见后进入待审，局部类别争议并未因分类高分而解决。

历史说明更正： 606图的 `sedd__00170` 实际有5个PL和1个BLOCK标注，不是“仅有PL标注”。其原始检测为6TP/1FP/0FN，旧融合将一个PL改为BLOCK后为5TP/2FP/1FN。本报告以保存的逐图标注与预测为准；该错误只涉及旧诊断文字，不改变原评分。

11 运行完整性与时间表现

11.1 样本和失败处理

运行	样本或候选数	最终失败数	保存的实际请求数	统计处理
606图纯 VLM	606	0	606	全部纳入
606图引导复检	606	0	680	包含补测，最终全部纳入
60图固定阈值首轮	60	1	60	失败图回退 YOLO，仍纳入
新增框二次确认	23个提议	2	23	失败提议不新增；60图分母不变

606图引导组最初有72张失败，补测过程又出现2次失败，合计保留74条失败重试记录。请求成功返回不必然意味着结构化解析成功，不能用 response 文件数量代替成功图片数。保守重放和本次分类复算新增模型请求数均为0。

早期 `live-60` 使用低阈值导出，最终有8张失败，不与本报告 conf=0.25 的60图主结果合并；小规模 smoke 运行亦不作为独立基准重复计数。

11.2 时间统计

测量	中位耗时	P95	口径
旧 YOLO26s 单图适配器	12.33 ms	27.06 ms	本地串行，排除加载和首次预热
新 YOLO26m 单图适配器	12.76 ms	27.88 ms	含读图、预处理、推理和结果转换
606图纯 VLM 保存记录	9.061 s	—	单条记录处理耗时
606图引导复检保存记录	7.069 s	—	最终保存尝试，不含已覆盖失败耗时
60图首轮保存记录	8.974 s	—	单条记录处理耗时
二次确认保存记录	9.142 s	—	单个提议处理耗时

VLM行不是纯网络延迟，也不是整个批次墙钟时间；不能把中位数乘图片数作为准确总时长，或由此宣称引导复检一定更快。现有汇总未形成完整Token／实际费用账本，故不提供推测的人民币费用或单图成本。

12 结论及验收适用范围

12.1 可以支持的结论

- 联合训练显著改善了SEDD留出数据适配，但五类不均衡仍明显，BX／FS是优先问题。
- 旧自动删改与新增框策略会同时影响已有召回和精确率；保守策略验证了原检测结果不被破坏。
- 对“图片中有哪些类别”这一任务，YOLO和保守融合有较高图像级分数；对“每处缺陷定位与计数”，框级成绩仍明显较低。
- VLM可提供解释、共存类别意见和待审核线索；这些业务辅助价值不自动等价于新增框的定量检测增益。

12.2 不应作出的推断

- 不将60图校准成绩外推为606图或未见管段表现，也不把框级与图像级计数混为同一准确率。
- 不将SEDD未标注的AJ／BX／FS当真阴性，不将所有额外预测都认定为错误或真实漏标。
- 不以旧YOLO26s的非独立参照结果断言新模型架构更差，不以单次API模型实验评价所有VLM。
- 不把后验策略重放当成新的前瞻独立测试：606图已用于诊断和指导融合改进，后续正式验收应增加未参与开发的固定样本。
- 不宣称正常管道误报控制已达标。606图仅2张、60图仅1张显式空标注，无法代表真实正常场景。

12.3 公司验收建议

若业务需要缺陷定位和数量，应以框级P／R／F1及mAP为主；若需要图片分流或类别检索，应以图像级Micro与Macro F1、逐类召回和整图完全正确率为主，不能只展示标签位准确率。

将“75%以上”明确到指标、类别和样本群体后，再设验收门。现有框级结果尚未证明融合总体达标；图像级部分指标超过75%，但不能替代定位验收。下一轮应优先人工复核BX／FS／PL分歧与新增候选，补足正常样本，并在新的独立固定集上比较所有方案。

附录A 补充统计与交付文件

A.1 训练后新旧模型的图像级参照

以下仍为9月17日缓存的离线分类投影，与第7节运行分开；旧模型受训练重叠限制。

方案	TP / FP / FN	P	R	F1	整图完全正确
旧 YOLO26s（参照）	550 / 9 / 71	98.39%	88.57%	93.22%	528/606（87.13%）
新 YOLO26m	525 / 29 / 96	94.77%	84.54%	89.36%	500/606（82.51%）

A.2 框级宏平均

与各主表的Micro指标配合，用于观察类别不均衡。

群体	方案	Macro P	Macro R	Macro F1
606对照	新 YOLO26m	64.37%	60.61%	61.87%
606对照	纯 VLM	23.81%	23.72%	22.44%
606对照	旧自动融合	45.08%	49.07%	46.40%
606对照	保守融合重放	64.37%	60.61%	61.87%
60校准	A 纯 YOLO	71.01%	63.53%	66.68%
60校准	B 保守融合	71.01%	63.53%	66.68%
60校准	C 首轮新增框	60.96%	65.07%	62.05%
60校准	D 二次确认新增框	62.45%	63.53%	62.23%

A.3 数据附件

文件	内容
REPORT.pdf	可直接发送和打印的完整报告，案例图已嵌入
REPORT.html	单文件浏览版，中文字体和案例图已嵌入
REPORT.md	可编辑正文；本地案例图链接需保留仓库相对路径
metrics.csv	300行总体、来源及逐类统计；比例以0至1小数保存
per_image_metrics.csv	3,876行图片—方案记录，包含类别集合、框级计数和整图正确标志
metrics.json	完整聚合、计分协议与一致性核对结果
collect_metrics.py	读取既有缓存并复算，不加载模型、不调用API

3,876行是606×2个训练后模型、606×4个对照方案及60×4个校准方案的记录数，不是3,876张独立图片。完整原始图库仍位于服务器实验归档，附件不包含数据集、模型权重或API密钥。

附录B 证据索引与复现

下列路径相对项目根目录。实验数据保留原始标签和逐图预测，不因本报告结论而修改。

编号	证据位置	用途
E1	.trellis/tasks/09-16-merged-five-dataset/report.md	数据清理、映射、分组与划分
E2	yolov26/configs/merged_five_yolo26m_5090.yaml	训练参数
E3	yolov26/docs/merged_five_yolo26m_evaluation_20260917.md	训练完成、性能与原生测试报告
E4	var/evaluations/2026-09-17-yolo26m/	新旧逐图预测、固定统计、原生AP与图库
E5	var/evaluations/2026-09-18-vlm-yolo26m-comparison/	606图两组state、请求证据、结果与图库
E6	var/evaluations/2026-09-18-vlm-calibration/replay/	保守与历史融合重放
E7	var/evaluations/2026-09-18-vlm-calibration/thresholds.json	完整验证集逐类阈值扫描
E8	var/evaluations/2026-09-18-vlm-calibration/live-60-conf025/	60图首轮固定工作点结果
E9	var/evaluations/2026-09-18-vlm-calibration/live-60-conf025-addition-confirmation/	23个新增提议二次确认
E10	.trellis/tasks/09-18-vlm-calibration-run/image_level_report.md	60图历史图像级与框级对照
E11	docs/experiment-cases/	已核对的两组实验图像摘录
E12	docs/reports/2026-11-09/metrics.json	本报告全部聚合统计与来源清单

离线复算及报告生成命令，在项目根目录执行：

```
.venv/bin/python docs/reports/2026-11-09/collect_metrics.py
.venv/bin/python docs/reports/2026-11-09/build_report.py
.venv/bin/python docs/reports/2026-11-09/render_report.py
```

复算保留完整分母，核对606图跨运行样本与标注一致、60图与测试集不重叠、保守重放逐图原框等价、二次确认候选身份一致，以及历史计数复现。报告引用的是9月实验策略，不表示后续应用版本或部署状态另行通过效果验收。